TP1 : Prétraitement de données

Objectif :
Se familiariser avec les étapes essentielles du prétraitement des données avant de construire un modèle de machine learning.
Nous utiliserons le jeu de données **Titanic** (disponible sur Kaggle ou d'autres sources publiques).
https://www.kaggle.com/datasets/brendan45774/test-file

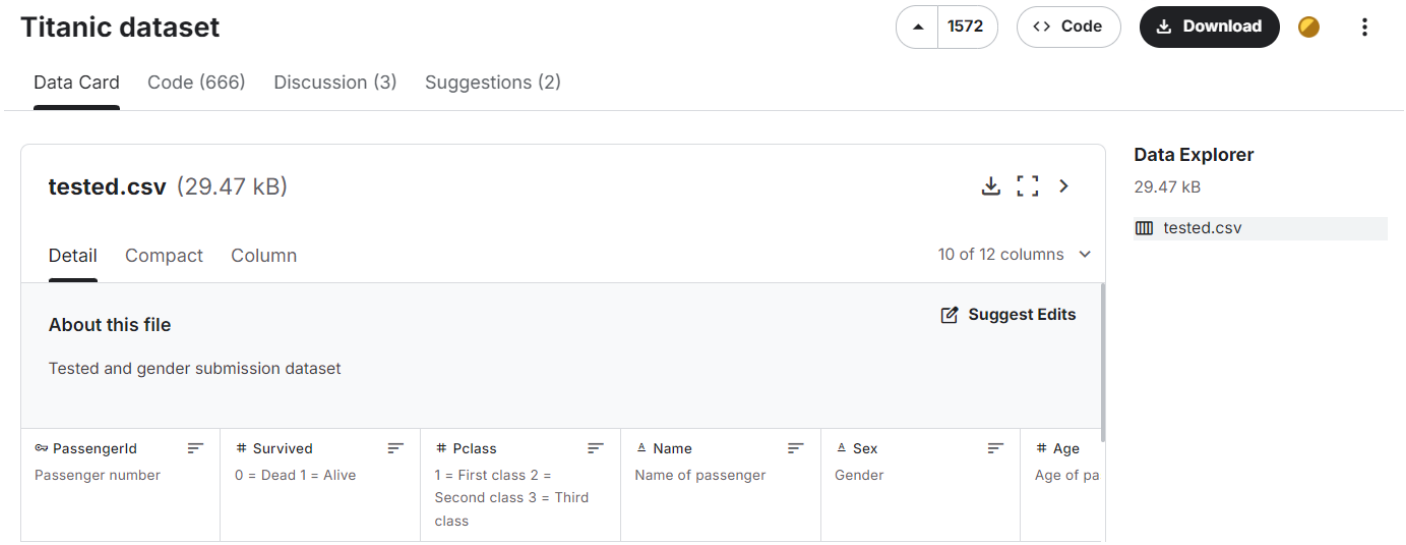

Etape1 : Exploration et données manquantes

Utilisez la bibliothèque pandas pour répondre aux questions suivantes :

1. Importez le dataset Titanic dans un DataFrame à l'aide de `read_csv()`.
   - Affichez les 5 premières lignes avec `head()` pour explorer sa structure.
2. Déterminez :
   - la taille du dataset (shape),
   - les différentes colonnes (features),
   - la variable cible (Survived).
   - Vérifiez s'il existe des valeurs manquantes.
3. Analysez la colonne Age :
   - Créez une variable age contenant cette colonne.

- Utilisez isnull() pour détecter les valeurs manquantes.
- Comptez le nombre de valeurs manquantes avec len().

4. Affichez le nombre de valeurs manquantes pour **toutes les colonnes**.
5. Question de réflexion :
   Pourquoi est-il important de traiter les données manquantes ? Quels sont les moyens possibles (suppression, imputation, etc.)

Etape 2 : Traitement des valeurs manquantes

1. Vérifiez la présence de valeurs manquantes dans la colonne Age.

- Comptez le nombre de valeurs manquantes.
- Supprimez les lignes contenant des valeurs manquantes dans Age.

2. Imputation des valeurs manquantes (si vous ne supprimez pas Age) :

- Remplacez les valeurs manquantes de la colonne Age par la moyenne des âges.
- Vérifiez que la colonne Age ne contient plus de valeurs manquantes après l'imputation.

Etape 3 : Encodage des variables catégoriques

Variable Sex (catégorique) :

- Transformez la colonne Sex en une variable numérique à l'aide d'un encodage (LabelEncoder ou One-Hot Encoding).
- Justifiez votre choix : pourquoi cet encodage est adapté à cette variable binaire (male / female) ?