TRAVAUX PRATIQUES

Machine Learning – KNN et Régression Logistique

Module : Machine Learning | **Niveau :** Master 1ère année

Durée estimée : 3 heures

CONTEXTE

Ce TP se concentre sur l'algorithme K-Nearest Neighbors (KNN), un algorithme de classification supervisée basé sur la proximité des données. Vous allez implémenter et évaluer KNN sur différents jeux de données en explorant ses paramètres et en analysant ses performances dans différents contextes. Comparer KNN avec Régression Logistique.

Algorithmes à implémenter

- **K-Nearest Neighbors (KNN)** avec k = {3, 5, 7, 9, 11}
- **Régression Logistique**

Datasets utilisés

- **Iris Dataset :** Classification de fleurs (3 classes, 4 features)
- **Wine Dataset :** Classification de vins (3 classes, 13 features)
- **Breast Cancer Dataset :** Diagnostic (2 classes, 30 features)

Métriques d'évaluation

- **Accuracy** (Exactitude)
- **Precision** (Précision)
- **Recall** (Rappel)
- **F1-Score**
- **Matrice de confusion**

PARTIE 1 : K-Nearest Neighbors (KNN)

Question 1.1 : Implémentation de KNN

Implémentez l'algorithme KNN en utilisant scikit-learn :

- Chargez les trois datasets (Iris, Wine, Breast Cancer)
- Divisez chaque dataset en ensemble d'entraînement (80%) et de test (20%)
- Normalisez les données avec StandardScaler
- Entraînez des modèles KNN avec k = 3, 5, 7, 9, 11
- Calculez les métriques pour chaque valeur de k

Question 1.2 : Choix de la métrique de distance

Testez différentes métriques de distance :

- **Distance euclidienne** (par défaut)
- **Distance de Manhattan**

Comparez les résultats et expliquez les différences observées

Question 1.4 : Optimisation du paramètre k

Déterminez la valeur optimale de k :

- *Tracez une courbe Accuracy vs k pour chaque dataset*
- *Identifiez la valeur optimale de k pour chaque dataset*
- *Expliquez pourquoi un k trop petit ou trop grand pose problème*
- *Utilisez la validation croisée pour confirmer votre choix*

PARTIE 2 : Évaluation et Analyse des Performances

Question 2.1 : Matrices de confusion

Pour chaque dataset et la meilleure valeur de k :

- Affichez et interprétez la matrice de confusion
- Identifiez les classes les plus confondues

Question 2.2 : Compromis Precision-Recall

Analysez le compromis entre Precision et Recall :

- Calculez Precision et Recall pour chaque classe
- Dans quel contexte privilégier la Precision ? Le Recall ?
- Pour le dataset Breast Cancer, quelle métrique est la plus importante et pourquoi ?
- Calculez le F1-Score et interprétez sa valeur

PARTIE 3 : Analyse Avancée et Visualisation

Question 3.4 : Comparaison globale

Synthèse et recommandations :

- Créez un tableau récapitulatif des performances sur les 3 dataset
- Pour quel type de problème KNN est-il le plus adapté ?
- Quelles sont les limites principales de KNN ?
- Proposez des améliorations ou alternatives possibles
- Discutez des avantages et inconvénients de KNN

PARTIE 4 : Comparer résultats de KNN avec Régression Logistique

Question : Implémentation de La Régression Logistique

Appliquer RL sur les 3 dataset et comparer le résultat avec KNN