TP N°2: Régression Lineaire

Le tableau ci-dessous présente des informations pour un total de 13 voitures, précisant à la fois leur année de fabrication et leur vitesse maximale respective.
L'objectif est d'examiner la corrélation potentielle entre l'âge des voitures et leur vitesse maximale.
La variable que l'on souhaite prédire (la vitesse) est appelée **variable dépendante**, tandis que la variable utilisée pour prédire la valeur de l'autre variable (l'âge) est appelée **variable indépendante**.

Year	2018	2016	2015	2016	2021	2006	2021	2014	2019	2012	2011	2014	2017
Speed	159	138	140	142	179	138	166	140	151	126	124	137	138
Power	38	15	200	50	30	80	80	85	110	150	60	55	110

1. Representation Graphique

Avec les valeurs de cet ensemble de données :

1. **Initialiser** deux simples tableaux NumPy à une dimension : x (âge des voitures) et y (vitesse maximale)
2. **Tracer** les données de manière à ce que :x-axis (l'**âge** des voitures), y-axis (**vitesse)**.
3. **Interprétation :**À partir du graphique obtenu, cette représentation permet d'**évaluer la pertinence d'un modèle linéaire** pour décrire la relation entre l'âge des voitures et leur vitesse maximale.

2. Quelques taches fondamentales

1. Créer un nouveau tableau X en concaténant le vecteur x avec un tableau rempli de uns. Pour cela, utilisez les fonctions **hstack** et **ones** de NumPy (assurez-vous de **redimensionner** le vecteur x au préalable à l'aide de reshape).
2. Créer un tableau θ de dimensions **(2,1)** et le remplir avec des valeurs aléatoires suivant une distribution normale standard (en utilisant la fonction random.randn()).
3. Implémenter l'équation suivante en utilisant deux méthodes différentes

$$Y_i = \vartheta_0 X_i + \vartheta_1 \quad \text{pour} \quad i = 1, 2, \ldots, n \ (n \text{ number of observations})$$

- Utiliser la boucle for standard.
- Utiliser la vectorisation offerte par la bibliothèque NumPy pour améliorer le temps d'exécution (en utilisant la fonction dot de NumPy).
- Pour apprécier les gains de performance de NumPy et mesurer le temps d'exécution du code, vous pouvez utiliser le module time de Python : time.time().

3. Modélisation du problème (Régression Linéaire Simple)

Si la relation entre l'âge (X) et la vitesse (Y) était parfaitement linéaire, nous pourrions l'exprimer comme suit :

$$Y = \vartheta_0 X + \vartheta_1$$

- Modéliser la relation linéaire entre l'âge d'une voiture (variable indépendante) et sa vitesse maximale (variable dépendante). Utilisez une solution analytique pour cela.

1. Utilisez la méthode de descente de gradient pour résoudre la question précédente :
2. Utilisez l'erreur quadratique moyenne (Mean Squared Error, MSE) comme fonction de coût
3. Tracez la droite de régression et la courbe correspondante de la fonction de coût pour illustrer le processus d'optimisation.
4. Utilisez l'erreur absolue moyenne (Mean Absolute Error, MAE) comme fonction de coût
5. Que remarquez-vous concernant le choix de la fonction de coût ?

4. Modélisation du problème (Régression Linéaire Multiple)

Si la relation entre (âge, puissance) (X1, X2) et la vitesse (Y) était parfaitement linéaire, nous pourrions l'exprimer comme suit :

$$Y = \vartheta_0 + \vartheta_1 X_1 + \vartheta_2 X_2$$

- Implémentez un code Python pour modéliser la relation linéaire entre la vitesse maximale d'une voiture (variable dépendante) et son âge ainsi que la puissance de son moteur (variables indépendantes). Utilisez une solution analytique pour cela.
- Utilisez la méthode de descente de gradient pour résoudre la question précédente.
- Tracez le plan de régression et la courbe correspondante de la fonction de coût pour illustrer le processus d'optimisation.