Université de Tlemcen

Faculté des Sciences

Département d'Informatique

Énoncé TP 0

I. Matériels nécessaires pour le TP

- Une distribution Python : **Anaconda** (Python + Jupyter Notebook)
- **scikit-learn** : est une bibliothèque Python à code source ouvert (open source) dotée d'outils puissants pour l'analyse et l'exploration de données.
- **NumPy** : un package nécessaire pour le calcul scientifique. Il comprend une structure incroyablement polyvalente pour manipuler les tableaux multidimensionnels, qui sont le principal format de données utilisé par scikit-learn pour les données en entrée.
- **SciPy** : une collection d'outils pour les statistiques en Python.
- **MatPlotLib** : une bibliothèque destinée à tracer et visualiser des données sous formes de graphiques.
- **Pandas** : une bibliothèque écrite pour le langage de programmation Python permettant la manipulation et l'analyse des données. Elle propose en particulier des structures de données et des opérations de manipulation de tableaux numériques et de séries temporelles.

II. Contexte et objectifs

- **Contexte:**

Les données utilisées ici sont célèbres dans le domaine des data sciences.Ce sont les mesures en centimètres des variables suivantes :longueur du sépale (*Sepal Length*),largeur du sépale (*Sepal Width*),longueur du pétale (*Petal Length*),largeur du pétale (*Petal Width*),

pour trois espèces d'iris : *setosa*, *versicolor* et *virginica*.

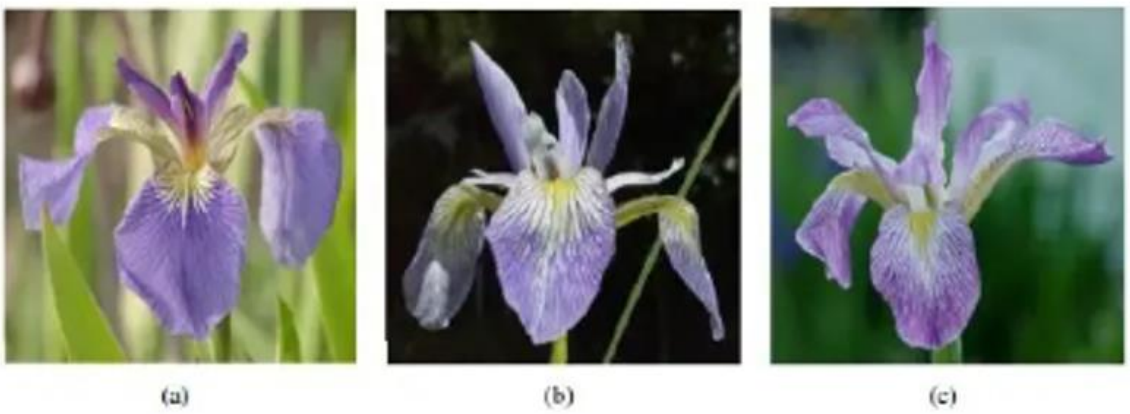

Figure1: (a) *setosa (b) versicolor (c) virginica*

- **Objectifs**

1. Familiariser l'étudiant avec le langage Python pour la data science.
2. Connaître et utiliser les librairies de base de Python pour la data science.
3. Charger et explorer le jeu de données comme celles des iris et autres.

III. Les étapes de réalisation de TP

Étape 1 : Lancement de l'éditeur et Importation des bibliothèques

Si la connexion internet le permet, il est plus facile d'utiliser les éditeurs de codes Python en ligne qui offrent un grand nombre d'avantages. Un des plus utilisés actuellement est **Google Colab** qui offre l'avantage de collaborer sur un code partagé en plus des ressources allouées. Mais il en existe beaucoup d'autres éditeurs en ligne comme Deepnote, Kaggle, etc. En cas de difficultés avec les éditeurs en ligne, il est mieux d'utiliser un éditeur en local comme **Spyder, Jupyter, Pycharm** etc. Ces éditeurs sont accessibles à travers l'installation d'**Anaconda** qui est une distribution libre et open source des langages Python et R.

NB : La structure du code ne changera pas selon qu'on utilise un éditeur en ligne ou en local ou encore selon le choix de l'éditeur.

1. Lancer l'éditeur Google Colab ou Jupyter d'Anaconda.
2. Importer les bibliothèques de base (pandas, numpy, matplotlib, seaborn)

Étape 2 : Charger et explorer les données

1. Charger le fichier **iris.csv** dans un DataFrame en utilisant la fonction `read_csv`
2. Afficher les premières et les dernières lignes pour comprendre la structure des données avec **head()** et **tail()**
3. Afficher nom des columns et le type de données avec **info()**
4. Vérifier les espèces présentes et leurs effectifs.
5. Sélectionner uniquement les colonnes numériques
6. Représentez graphiquement la **répartition des espèces d'Iris** (Setosa, Versicolor, Virginica). Les classes sont-elles équilibrées ?
7. Tracez un **pairplot** (diagrammes en nuages de points pour chaque paire de variables). Quelles espèces semblent **facilement séparables** visuellement ?

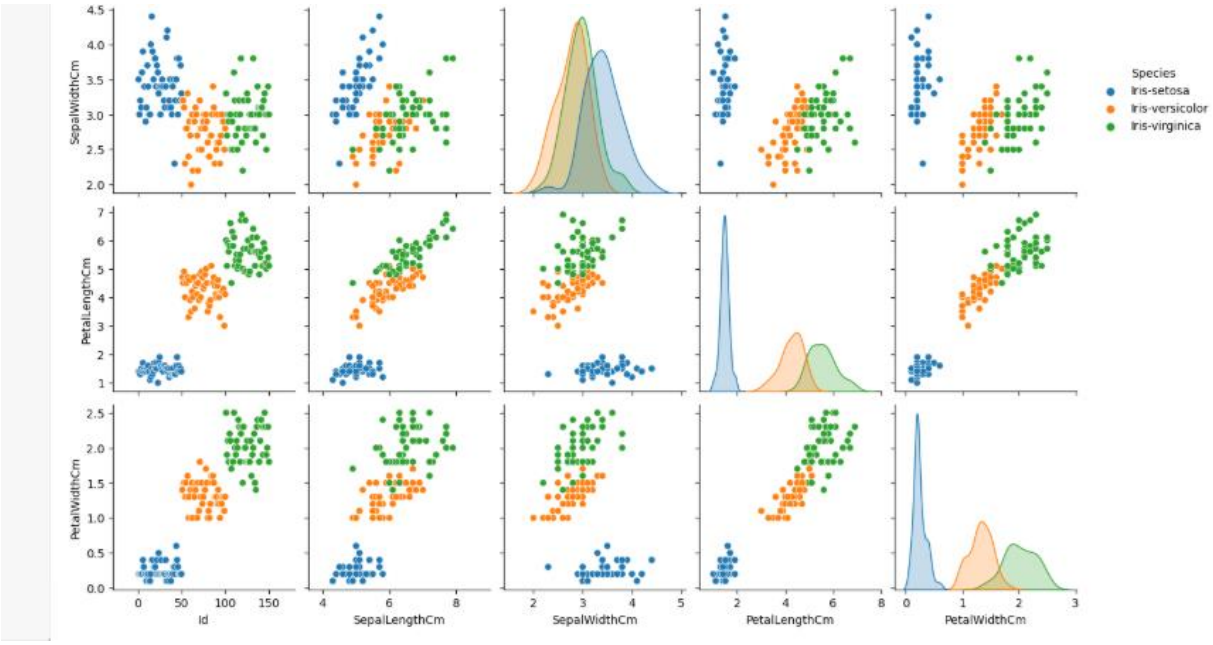

Figure 2 : Une partie de l'affichage du pairplot

8. Visualiser les données 3d. Essayer plusieurs combinaisons possibles (voir ci-dessous Figure1).

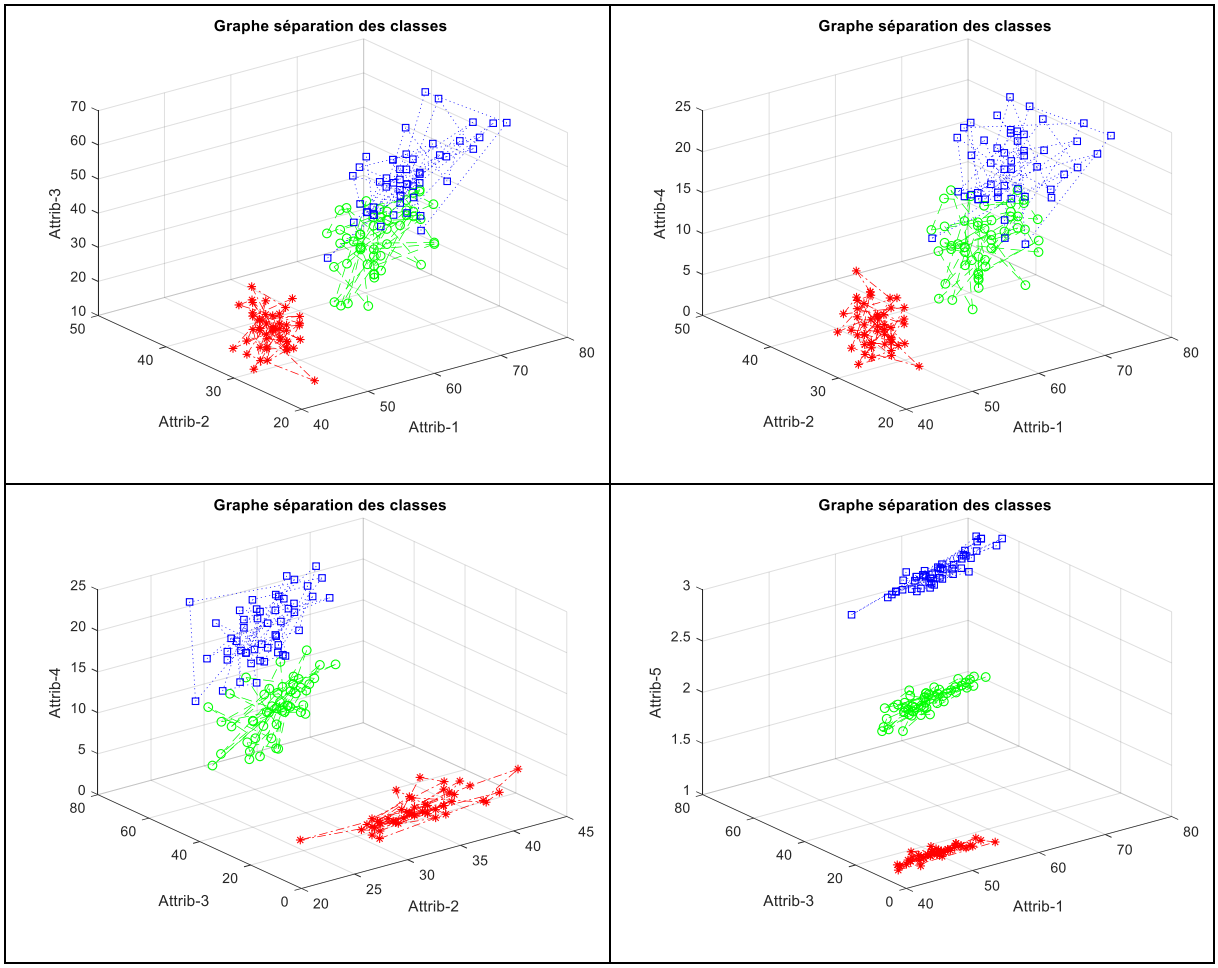

Figure3 (rouge pour classe1, vert pour classe 2 et bleu pour classe3)

9. Quelles variables sont fortement corrélées ?
10. Réaliser une projection des vecteurs caractéristiques dans un espace 3d en effectuant une analyse en composantes principales (ACP).

Étape 3 : Prétraitement de données

- ✓ Chargement d'un jeu de données (dataset)

```
from sklearn import datasets
digits=datasets.load_digits()
boston=datasets.load_boston()
```

- ✓ Prétraitement de données : package **sklearn.preprocessing**
  - Standardisation : scale(X), MinMaxScalar(),..
  - Normalisation : normalize(X)
  - Codage des attributs catégoriels : OrdinalEncoder